



לא לשכוח להפעיל הקלטה!




✓ פונקציה לוגיסטית

✓ Cost function לרגרסיה לוגיסטית

✓ gradient descent עבור רגרסיה לוגיסטית

✓ בעיות סיווג לשתי מחלקות

# רגרסיה לוגיסטית



# רגרסיה לוגיסטית

- אלגוריתם סיווג
- מחשב את ההסתברות שדוגמא לא ידועה שייכת לכל אחד מהסוגים
- שיטת החישוב: מציאת ערכי המשקולות  $w$  ו- $b$  כאשר ערך הטעות מפונקציית המחיר היא מינימלית

# פונקציה לוגיסטית


# פונקציה לוגיסטית

כאשר  $z$  הינו הקלט  
המשוקלל לנוירון

$$\hat{y} = \frac{1}{1+e^{-z}}$$

$$\sum_{i=1}^n w(i)x(i) + b$$

n-מספר התכונות לא  
כולל הטיה



# פונקציה לוגיסטית - משמעות

אם  $z = 0$

ערך הפונקציה שווה ל-0.5.


אם  $z$  חיובי מאוד – ערך

הפונקציה שואף ל-1.

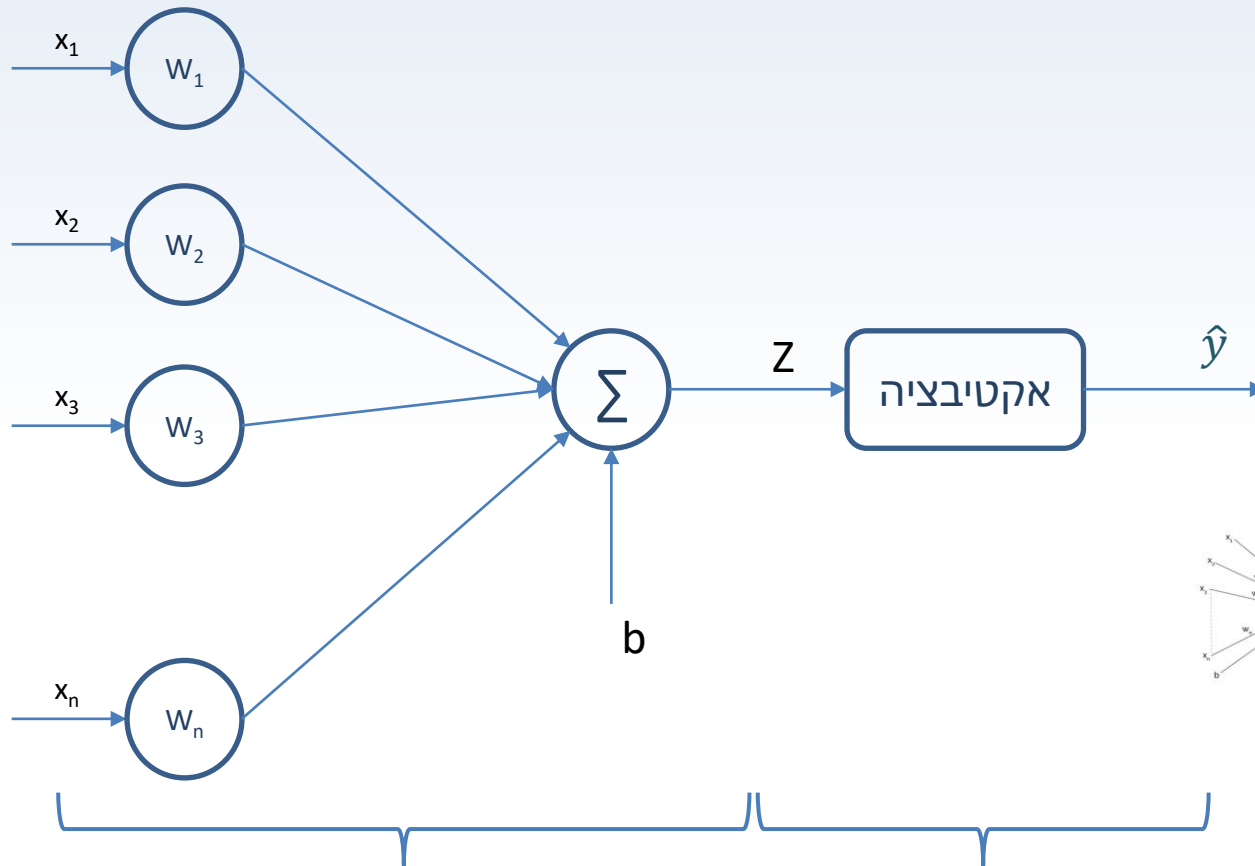
אם  $z$  שלילי מאוד – ערך

הפונקציה שואף ל-0.

בין לבין, ערכי הפונקציה רציפים  
קיבלנו את הפונקציה הלוגיסטית  
פונקציה רציפה בין 0 ל-1,  
הניתנת לגזירה




# ארכיטקטורה של ניורון בודד



חלק הלינארי של הניורון

חלק האקטיבציה





# תרגיל 1

## סיווג על ידי רגרסיה לוגיסטית

- נתונות תמונות בעלות שני מאפיינים:

- $x_1$  ממוצע האדום בתמונה

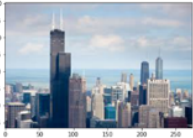
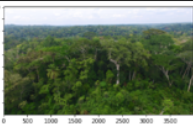


- $x_2$  ממוצע הכחול בתמונה

- נתון מסווג מסוג רגרסיה לוגיסטית בעל הפרמטרים הבאים:

- $w_1=0.06$

- $w_2=0.04$

- $b=-10$

Image	$x_1$ (red)	$x_2$ (blue)	$z = w_1 \cdot x_1 + w_2 \cdot x_2 + b$	$\hat{y} = \sigma(z)$	סוג יער=0 עיר=1
	153	173			
	93	83			
	81	124			
	90	18			

# פונקציות טווחים ב PYTHON

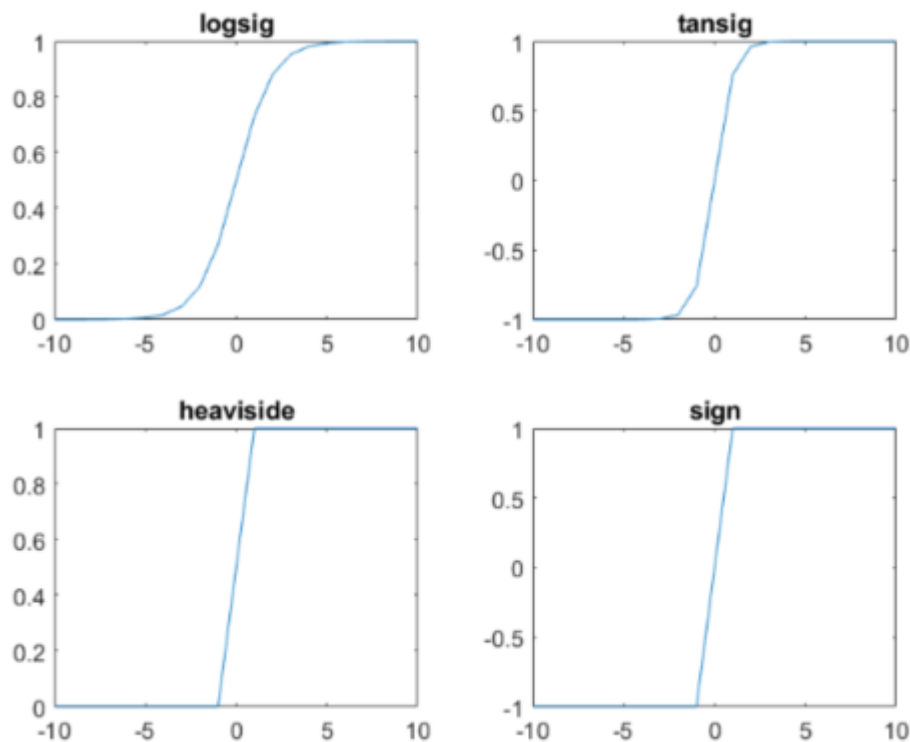
שם	טווח	רציפה	ויזואליזציה
לוגיסטית	0 עד 1	כן	
מדרגה	0 עד 1	לא	
טנגנס היפרבולי	-1 עד 1	כן	
סימן	-1 עד 1	לא	

# תרגיל 2

## PYTHON פונקציות טווחים ב

**(מחברת Colab):**

הציגו על המסך 4 גרפים שמייצגים את פונקציות הטווחים  
צרו וקטור ערכים לציר ה X מ -10 עד 10 במרווחים של 1



# סיווג לשתי מחלקות

# משמעות הפלט של הניורון בפונקציה לוגיסטית

הערכים בפלט: כל ערך בין 0 ל 1

נניח שיש לנו בעיית סיווג:

נתונים של קוטר האבטיח. וכתשובה האם הפרי בשל או לא

✓ אם הפלט 1 – הפרי בשל, אם הפלט 0 – הפרי לא בשל

✓ המודל סיווג 0.83 – מה המשמעות?

0.83 אומר שיש סיכוי של 83% שהפרי בשל, ושל 17% שהפרי אינו בשל.

✓ המודל סיווג 0.83 – האם הפרי בשל?

מעל 0.5 – נקבע שהפרי בשל, מתחת ל 0.5 נקבע שהפרי לא בשל.

אימנת מודל סיווג שמנבא האם תלמיד יסיים תואר ראשון על  
סמך נתוני הבחינה הפסיכומטרית  
הפלט עבור דוגמא חדשה חזה  $h=0.7$   
אילו מההגדים נכונים?

- A ☐ 70% שהתלמיד יסיים תואר I
- B ☐ 30% שהתלמיד יסיים תואר I
- C ☐ 100% שהתלמיד יסיים תואר I
- D ☐ 30% שהתלמיד לא יסיים תואר ראשון

אימנת מודל סיווג שמנבא האם תלמיד יסיים תואר ראשון על סמך נתוני הבחינה הפסיכומטרית  
הפלט עבור דוגמא חדשה חזה  $h=0.7$   
אילו מההגדים נכונים?

נכון

A ☐ 70% שהתלמיד יסיים תואר |

B ☐ 30% שהתלמיד יסיים תואר |

C ☐ 100% שהתלמיד יסיים תואר |

נכון

D ☐ 30% שהתלמיד לא יסיים תואר ראשון

# משמעות הפלט של הניורון

## בפונקציה לוגיסטית

ערך הפונקציה הלוגיסטית שווה ל-50% כאשר הקלט המשוקלל שווה ל-0.  
לכן:

אם $z$ גדול שווה	מ 0 – נסווג למחלקה אחת ( $y=1$ )
אם $z$ קטן	מ 0 – נסווג למחלקה אחרת ( $y=0$ )

קו ההחלטה (ה-decision boundary) הוא  $Z = \sum_{i=1}^n w(i)x(i) + b = 0$

$$w = [-1 \ 0], b = 5$$

$$y = 1 \text{ if } (-1)x_1 + 0x_2 + 5 \geq 0$$

$$5 - x_1 \geq 0$$

$$-x_1 \geq -5$$

$$x_1 \leq 5$$

$$\text{אם } y = 1, Z \geq 0$$

$$\text{אם } y = 0, Z < 0$$



אימנת מודל סיווג שמנבא האם תלמיד יסיים תואר ראשון על סמך נתוני הבחינה הפסיכומטרית  $x_1$  ונתוני ציוני הבגרות  $x_2$ :

$$\hat{y} = \frac{1}{1 + e^{-z}}, z = w_1 x_1 + w_2 x_2 + b$$


המשקולות של המודל שלך הם:

$$0 = w_1$$

$$-1 = w_2$$

$$6 = b$$

איזה גרף מציין נכון את קו ההפרדה של הנתונים:



אימנת מודל סיווג שמנבא האם תלמיד יסיים תואר ראשון על סמך נתוני הבחינה הפסיכומטרית  $x_1$  ונתוני ציוני הבגרות  $x_2$ :

$$\hat{y} = \frac{1}{1 + e^{-z}}, z = w_1 x_1 + w_2 x_2 + b$$


המשקולות של המודל שלך הם:

$$0 = w_1$$

$$-1 = w_2$$

$$6 = b$$

איזה גרף מציין נכון את קו ההפרדה של הנתונים:




# Cost function עבור רגרסיה לוגיסטית

# פונקציית המחיר - BINARY CROSS ENTROPY

$$l^{(i)} = -y^{(i)} \log \hat{y}^{(i)} - (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})$$

$$J = \frac{1}{m} \sum_{i=1}^m l^{(i)}$$



$\hat{y}^{(i)}$  – הערך החזוי בכל דגימה

$$\hat{y}^{(i)} = \left( \frac{1}{1 + e^{-z^{(i)}}} \right)$$

$y^{(i)}$  – הערך האמיתי בכל דגימה

$m$  – מספר הדגימות

$i$  – אינדקס על כל הדגימות

# תרגיל 3

## חישוב פונקציית מחיר

נתונות הדוגמאות הבאות. חשבו את פונקציית המחיר על כל אחת מהדוגמאות ואת המחיר הכולל  $J$

$i$	$y^{(i)}$	$\hat{y}^{(i)}$	$-y^{(i)} \log \hat{y}^{(i)} - (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})$
1	0	0.1	
2	0	0.5	
3	0	0.6	
4	1	0.9	
5	1	0.5	
6	1	0.4	

$$J = \frac{1}{6} \sum_{i=1}^6 l^{(i)} = ?$$


# המטרה – למזער את הטעות עבור ערכי המשקולות השונים

$$\hat{y} = \frac{1}{1+e^{-z}} \quad \left\{ \begin{array}{l} \text{if } \hat{y} \geq 0.5, y_{\text{predicted}} = 1 \\ \text{if } \hat{y} < 0.5, y_{\text{predicted}} = 0 \end{array} \right.$$

Cost Function

$$J = \left\{ \begin{array}{ll} -\log(\hat{y}) & \text{if } y = 1 \\ -\log(1 - \hat{y}) & \text{if } y = 0 \end{array} \right.$$

# פונקציית העלות עבור $Y=1$ $-\log(\hat{y})$




$$0 < \hat{y} < 1$$

כאשר  $\gamma=1$  וגם הפלט הוא 1 – ה-cost הוא 0.

כאשר  $\gamma=1$  אבל הפלט הוא 0 – ה-cost שואף לאינסוף

# פונקציית העלות עבור $Y=0$

$$-\log(1 - h(w,x))$$



$$0 < h(w,x) < 1$$

כאשר  $\gamma=0$  וגם הפלט הוא 0 – ה-cost הוא 0.

כאשר  $\gamma=0$  אבל הפלט הוא 1 – ה-cost שואף לאינסוף




# תרגיל 4

## ויזואליזציה של פונקציית המחיר

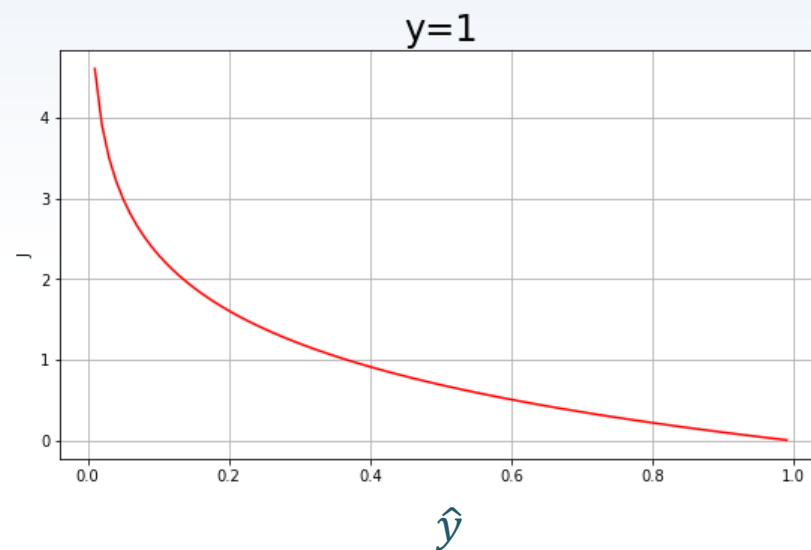
- שרטטו את פונקציית המחיר עבור דוגמאות מסוג "0" שהחיצוי עבורן בתחום 0.0-0.99
- שרטטו את פונקציית המחיר עבור דוגמאות מסוג "1" שהחיצוי עבורן בתחום 0.01-1.0

# ויזואליזציה של פונקציית המחיר

$$J = -\log(1 - \hat{y}^{(i)})$$



$$J = -\log(\hat{y})$$



# אלגוריתם GRADIENT DESCENT

- הגדרנו את פונקציית המחיר

$$J(w, b)$$

- נאתחל:

$$w \leftarrow 0, b \leftarrow 0$$

- נתקדם לכיוון המינימום:

$$w \leftarrow w - \alpha \frac{\partial J(w, b)}{\partial w}$$

$$b \leftarrow b - \alpha \frac{\partial J(w, b)}{\partial b}$$

# אלגוריתם GRADIENT DESCENT לאימון

## רגרסיה לוגיסטית

- הגדרנו את פונקציית המחיר

$$J(w, b)$$

- נאתחל:

$$w \leftarrow 0, b \leftarrow 0$$

- נתקדם לכיוון המינימום:

השגיאה בין הערך החזוי לאמיתי

$$w \leftarrow w - \alpha \frac{1}{m} \sum_{i=1}^m \underbrace{(\hat{y}^{(i)} - y^{(i)})}_{\text{השגיאה}} x^{(i)}$$

$$b \leftarrow b - \alpha \frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})$$

שאלות למחשבה:

- מהם ההבדלים בין נוסחאות האימון של רגרסיה לוגיסטית לרגרסיה לינארית?
- מהם ההבדלים בין נוסחאות האימון של רגרסיה לוגיסטית לפרספטרון?

# gradient descent עבור רגרסיה לוגיסטית

# האם GRADIENT DESCENT עבור

רגרסיה לינארית ועבור רגרסיה

לוגיסטית זהה?

$$w(j) = w(j) - (\alpha/m) \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)}) x(j)(i)$$

ברגרסיה לוגיסטית:

$$\hat{y}^{(i)} = \frac{1}{1 + e^{-\sum_{j=1}^n w(j)x(j) + b}}$$

ברגרסיה לינארית:

$$\hat{y}^{(i)} = \sum_{j=1}^n w(j)x(j) + b$$

# הערכת ביצועים עבור רגרסיה לוגיסטית

# חישוב אחוז הדגימות שהמודל צדק בהם

$\gamma$  - וקטור הערכים האמיתיים, ערכים בידיים 0 או 1

0	0	0	0	1	1	1	1	1	1
---	---	---	---	---	---	---	---	---	---

$\hat{\gamma}$  - וקטור הערכים החזויים, ערכים בין 0 ל 1

0.2	0.1	0.3	0.6	0.8	0.6	0.4	0.9	0.8	0.7
-----	-----	-----	-----	-----	-----	-----	-----	-----	-----

if  $\hat{\gamma} \geq 0.5$ ,  $p=1$   
if  $\hat{\gamma} < 0.5$ ,  $p=0$

$p$  - וקטור הערכים החזויים, ערכים בידיים 0 או 1

0	0	0	1	1	1	0	1	1	1
---	---	---	---	---	---	---	---	---	---

Accuracy = all correct samples / all samples = 8/10, 80%



# רגרסיה לוגיסטית ב SKLEARN

- `from sklearn.linear_model import LogisticRegression`
  - `X=df[['...']].to_numpy()`
  - `y=1*(df[['...']]>...).to_numpy()`
  - `clf = LogisticRegression()`
  - `clf.fit(X, y)`
- # ייבוא ספרייה
  - # בחירת מאפיינים
  - # בחירת תנאי לוגי
  - # הגדרת מסווג
  - # אימון