






לא לשכוח להפעיל הקלטה!



רגרסיה ברשתות נוירונים



מה אנחנו צריכים כבר לדעת?

- למידה מפוקחת
- רגרסיה לוגיסטית ופונקציית מעבר
- מבנה הרשת
- קלסיפיקציה ברשתות ניורונים

- ✓ בעיות רגרסיה - דוגמאות ומאפיינים
- ✓ בעיות רגרסיה – ייצוג של הערכים בקלט ובפלט
- ✓ אימון הרשת
- ✓ הערכת ביצועי הרשת



סוגי הבעיות בלמידה מונחית


רגרסיה


- מציאת הפונקציה בין הקלט לפלט.
- הפלט הוא מספר ממשי בעל משמעות.

קלסיפיקציה


- כל אינפוט שייך למחלקה מסוימת
- עלינו לגלות לאיזו מחלקה האינפוט שייך
- הפלט הוא בינארי-שייך/לא שייך למחלקה

- פונקציות פשוטות (למשל, רגרסיה ליניארית)





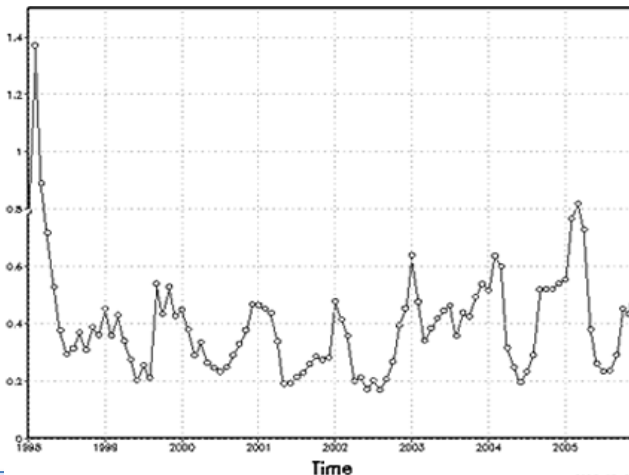
- הערכת מחירי בתים:
 - האינפוט: מספר החדרים, יחס מורים:תלמידים בעיר, נגישות לדרכים מהירות וכו'.
 - אאוטפוט: מחיר ממוצע של בית.
- הערכת אחוז פשיעה בעיר:
 - אינפוט: מצב סוציו-אקונומי, צפיפות האוכלוסיה, טיב החינוך, חומרת הענישה בבית המשפט וכו'.
 - אאוטפוט: אחוז הפשיעה החמורה, אחוז העבירות הקלות, אחוז עבירות צווארון לבן.
- גם באאוטפוט יכולים להיות כמה מספרים.




- חיזוי סדרת זמן
(time series)
:(prediction

חיזוי ערך מניה
בבורסה
בהתבסס על
ערכי המניה
בימים הקודמים.

- נניח שאנחנו רוצים לחזות את ערכי מניית google:
 - האינפוט: ערכי מניית google ב-5 ימים הקודמים.
 - האאוטפוט: ערכי מניית google ביום השישי.
- אבל אולי ערכי מניית google תלויים גם בערכי מניית apple?
 - האינפוט: ערכי מניית google וערכי מניית apple ב-5 ימים הקודמים.
 - האאוטפוט: ערכי מניית google ביום השישי.





- חיזוי הרווח בסרט על סמך נתונים כגון שחקנים, במאי, השקעה כספית בסרט וכו'.



- חיזוי מיקום בתמונה של נקודה אנטומית.

ייצוג של הערכים בקלט ובפלט

• נתונים סטטיסטיים

input: הפיצ'רים הינם ערכים מספריים


output: ערכים מספריים

Regression

מוכנות להוצאה על חופשה בחו"ל

אברהם	מקרר	3000	8:00	20000
אברהם	מסטיק	5	9:45	20000
שרה	חנייה	40	10:02	10000
שרה	חשבון חשמל	3000	15:33	10000
שרה	ספה	3000	9:01	10000
יצחק	מכולת	25	18:45	0
יצחק	שעון יד	300	23:23	0
יצחק	מקרר	3000	8:00	0
רבקה	טלוויזיה	6600	17:02	3000
רבקה	מזון לחתולים	30	02:30	3000

יעקב	קפה ומאפה	50	06:30	?
------	-----------	----	-------	---



בעיית רגרסיה ב Keras

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from tensorflow import keras
from tensorflow.keras import layers

from sklearn.datasets import fetch_california_housing
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense
```

טעינת הנתונים:

- X – נתוני ה input

בשורות – מספר הדגימות

בעמודות – מספר הפיצ'רים

- y – הפלט נתוני ה output

בשורות – מספר הדגימות

בדרך כלל עמודה אחת עם הערכים מספריים

גם X וגם y מסוג numpy


```
# Build the model
model = Sequential([
    Dense(64, activation='relu', input_shape=(X_train.shape[1],)),
    Dense(64, activation='relu'),
    Dense(1) # Output layer for regression
])

model.compile(optimizer='adam', loss='mean_squared_error')

# Train the model
history = model.fit(X_train, y_train, epochs=20, validation_data=(X_val, y_val),
batch_size=32)
```

*** פרמטרים שניתנים לשינוי ליצירת רשת במבנה רצוי

תוצאת אימון הרשת

```
i=0
for layer in model1.layers:
    i=i+1
    weights, biases = layer.get_weights()
    print("w", str(i), weights.shape, ";b", str(i), biases.shape)
```

משקולות וערכי הספים בכל השכבות:


```
w 1 (4, 64) ;b 1 (64,)
w 2 (64, 64) ;b 2 (64,)
w 3 (64, 3) ;b 3 (3,)
```

הטעות סט האימון בכל האיטרציות:

```
model_history.history['loss']
```

הדיוק accuracy אינו רלוונטי בבעיות הרגרסיה

תצוגה גרפית של תוצאת האימון של המודל



- בבעיות קלסיפיקציה השתמשנו בעיקר באחוז ההצלחה של הרשת ככלי להעריך את ביצועיה.
- בבעיות רגרסיה נשתמש בחישוב ערכי השגיאות ב-3 שיטות:
MSE, MAE, RMSE

Calculate MSE

```
test_loss = model.evaluate(X_test, y_test)
print(f"Test Loss (MSE): {test_loss}")
from sklearn.metrics import mean_absolute_error, mean_squared_error
mse = mean_squared_error(y_test, y_pred)
print(f"Mean Squared Error (MSE): {mse}")
```

Calculate MAE


```
mae = mean_absolute_error(y_test, y_pred)
print(f"Mean Absolute Error (MAE): {mae}")
```

Calculate RMSE (the square root of MSE)

```
rmse = np.sqrt(mean_squared_error(y_test, y_pred))
print(f"Root Mean Squared Error (RMSE): {rmse}")
```

הערכת ביצועי הרשת – correlation coefficient

דרך טובה להעריך את הביצועים היא לצייר גרף, בו בציר x נמצא הפלט הרצוי, ובציר y – פלט הרשת.

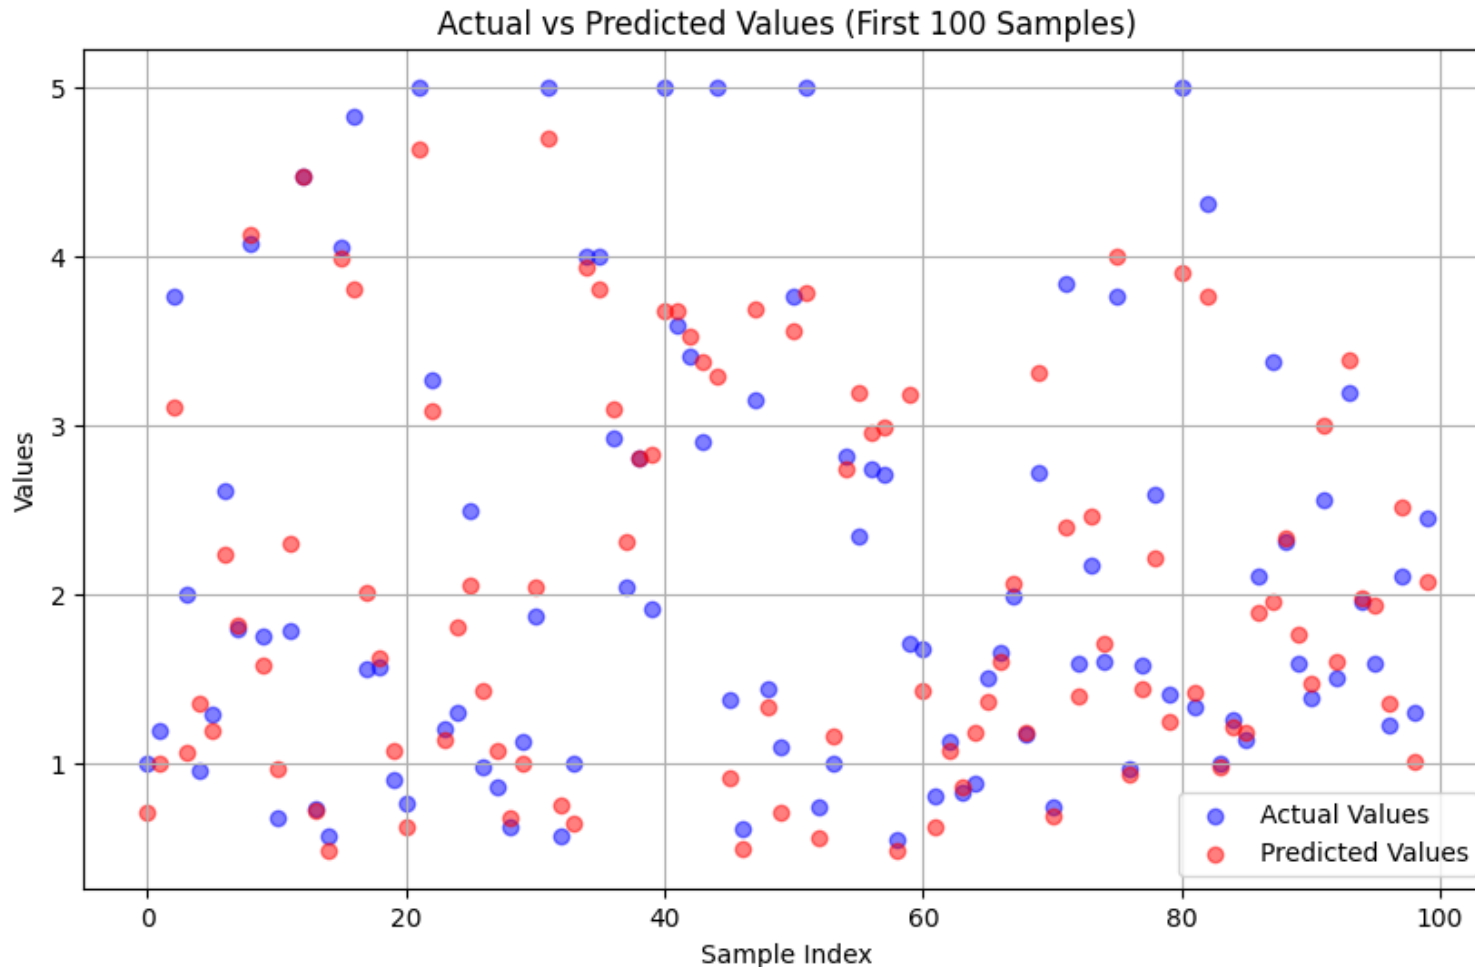


פרמטר סטטיסטי מהווה מדד למידת ההתאמה הליניארית

ערכו נע בין -1 ל 1:

- -1 (קורלציה שלילית מושלמת)
- +1 (קורלציה חיובית מושלמת)
- 0 (אין קורלציה)

נציג על אותה רשת צירים את הפלט של הרשת לעומת הערך האמיתי



הגדרות הרשת לפני ההרצה

- כיצד נדע כמה שכבות חביות אנחנו צריכים?

- יתכן שאין כלל צורך בשכבות חביות!

- הרבה פעמים עדיף להתחיל ממודל פשוט (למשל פרספטרון פשוט במקרה של בעיית קלסיפיקציה, או נוירון עם פונקצית מעבר ליניארית במקרה של בעיית רגרסיה).

- תיאורטית נמצא ששכבה חבויה אחת מספיקה על מנת לבצע התאמה לכל פונקציה.

- לעיתים המשימה החישובית תהיה קלה יותר עם מספר שכבות גדול יותר.

הגדרות הרשת – מספר הנירונים החבויים

- כיצד נדע כמה נירונים חבויים אנחנו צריכים?
 - פחות מדי נירונים – under fitting.
 - יותר מדי נירונים – over fitting.
- מספר הנירונים האידיאלי ליכולת הכללה טובה תלוי בצורה שאינה ידועה ב:
 - מספר נירוני האינפוט והאאוטפוט.
 - מספר דוגמאות האימון (הקלטים).
 - כמות הרעש בתשובות הנכונות.
 - מידת הסיבוכיות בבעיית הרגרסיה או הקלסיפיקציה.
 - ארכיטקטורת הרשת.
 - אלגוריתם האימון.
 - פונקציית המעבר של הנירונים.
- הכי טוב – לנסות ולראות.
 - את אחוז ההצלחה בהינתן כל מספר של נירונים חבויים נעריך על סט הולידציה, ולא על סט הבחינה.